
Prédiction du Churn Client dans le Secteur des Télécommunications

Data Preprocessing & Feature Selection

Dataset : Telco Customer Churn — IBM / Kaggle

Étudiants :

Moustapha 22013@supnum.mr

Ahmed Mouloud 22051@supnum.mr

0 Table des matières

1	Introduction et Description du Problème	2
1.1	Contexte	2
1.2	Objectifs	2
1.3	Dataset	2
1.4	Dictionnaire des variables	2
2	Analyse Exploratoire (EDA)	4
2.1	Variable cible	4
2.2	Variables numériques	4
2.3	Variables catégorielles	6
3	Prétraitement des Données	7
3.1	Étape 1 — Imputation des valeurs manquantes	7
3.2	Étape 2 — Valeurs aberrantes (Outliers)	8
3.3	Étape 3 — Encodage catégoriel	9
3.4	Étape 4 — Ajustement d'échelle	10
3.5	Étape 5 — Feature Engineering	11
3.6	Pipeline final	12
4	Sélection de Caractéristiques	13
4.1	Famille 1 — Filter Methods	13
4.2	Famille 2 — Wrapper Methods	14
4.3	Famille 3 — Embedded Methods	14
4.4	Consensus et résultat	15
5	Expériences et Résultats	17
5.1	Protocole	17
5.2	Résultats — Pipeline final (25 features)	17
5.3	Impact du prétraitement vs baseline	17
5.4	Courbes ROC et validation croisée	18
5.5	Meilleur modèle	18
6	Conclusions	19
6.1	Synthèse des choix	19
6.2	Top features — unanimité	19

1 Introduction et Description du Problème

1.1 Contexte

Le *churn* (attrition client) désigne la résiliation d'un abonnement. Dans le secteur des télécommunications, acquérir un nouveau client coûte 5 à 7 fois plus cher que de fidéliser un client existant. Prédire le churn avec précision permet de cibler les interventions de rétention avant la résiliation.

1.2 Objectifs

- Appliquer les méthodes de prétraitement vues en cours (imputation, scaling, encodage, outliers)
- Expérimenter les 3 familles de Feature Selection (Filter, Wrapper, Embedded)
- Mesurer l'impact de chaque décision sur les performances de 4 modèles
- Justifier chaque choix méthodologique selon le cadre : *Problème* → *Solutions* → *Choix* → *Preuve*

1.3 Dataset

TABLE 1 – Caractéristiques du dataset Telco Customer Churn (Kaggle/IBM)

Attribut	Valeur	Remarque
Lignes	7 043	Clients d'un opérateur télécoms californien
Variables initiales	21 (dont 1 ID)	3 numériques, 17 catégorielles, 1 cible
Variable cible	Churn Yes/No	Résiliation le mois dernier
Taux de churn	26.5%	Dataset déséquilibré (ratio 2.8 :1)
Valeurs manquantes	11 (TotalCharges)	Clients avec <code>tenure=0</code>

1.4 Dictionnaire des variables

Variable	Type	Modalités	Description
gender	Binaire	Male/Female	Genre
SeniorCitizen	Entier 0/1	0,1	Personne âgée ≥ 65 ans
Partner	Binaire	Yes/No	A un partenaire
Dependents	Binaire	Yes/No	A des personnes à charge
tenure	Numérique	0–72	Ancienneté en mois
PhoneService	Binaire	Yes/No	Service téléphonique
MultipleLines	Catégorielle	3	Lignes multiples
InternetService	Catégorielle	DSL/Fibre/Non	Type de connexion
OnlineSecurity	Catégorielle	3	Sécurité en ligne
OnlineBackup	Catégorielle	3	Sauvegarde en ligne
DeviceProtection	Catégorielle	3	Protection appareil
TechSupport	Catégorielle	3	Support technique
StreamingTV	Catégorielle	3	TV streaming

Variable	Type	Modalités	Description
StreamingMovies	Catégorielle	3	Films streaming
Contract	Ordinale	3 niveaux	Type de contrat
PaperlessBilling	Binaire	Yes/No	Facturation dématérialisée
PaymentMethod	Catégorielle	4	Mode de paiement
MonthlyCharges	Numérique	18–119 \$	Facture mensuelle
TotalCharges	Numérique/str	0–8685 \$	Cumul factures (11 NAs cachés)
Churn	Cible	Yes/No	A résilié le mois dernier

2 Analyse Exploratoire (EDA)

2.1 Variable cible




FIGURE 1 – Distribution de la variable cible — déséquilibre 73.5% / 26.5%

Le déséquilibre impose `class_weight='balanced'` dans tous les modèles et ROC-AUC comme métrique principale.

2.2 Variables numériques

TABLE 3 – Statistiques descriptives — variables numériques

Variable	Min	Médiane	Moyenne	Max	Moy. churners
tenure	0	29	32.4	72	17.9
MonthlyCharges	18.3	70.4	64.8	118.8	74.4
TotalCharges	0	1 397	2 283	8 685	1 532




FIGURE 2 – Distributions KDE et boxplots — variables numériques par classe

2.3 Variables catégorielles




FIGURE 3 – Taux de churn par modalité

Résultats clés : Contract mois-par-mois → 43% de churn ; Fibre optique → 42% ; sans OnlineSecurity → ~42%.

3 Prétraitement des Données

Pour chaque décision, nous appliquons le cadre d'analyse : **Pourquoi ce problème existe-t-il ?** → **Quelles solutions ?** → **Pourquoi ce choix ?** → **Preuve expérimentale.**

3.1 Étape 1 — Imputation des valeurs manquantes

Problème

TotalCharges est stocké en **object** : 11 lignes contiennent un espace blanc au lieu d'un nombre. Ces clients ont **tenure=0** (jamais facturés). Origine : export CSV du système de facturation, le champ est vide si aucune facture n'a encore été émise.

Solutions possibles (cours slide 4) :

Stratégie	Méthode	Lignes	AUC (RF)
Suppression	<code>dropna()</code>	7 032	0.8221
Constante (0)	<code>fillna(0)</code>	7 043	0.8241
Moyenne	<code>fillna(mean)</code>	7 043	0.8241
Régression	<code>IterativeImputer</code>	7 043	0.8240

Décision retenue

Constante (0). **tenure=0** ⇒ aucun mois facturé ⇒ **TotalCharges = 0** est sémantiquement correct. Préserve 100% des données. La suppression perd 11 lignes inutilement.

Preuve expérimentale

Les 4 stratégies donnent AUC dans $[0.822, 0.824]$: différence < 0.002 , négligeable. La constante 0 est donc optimale (sans perte d'information, justifiée par le domaine).




FIGURE 4 – Impact des stratégies d'imputation sur ROC-AUC

3.2 Étape 2 — Valeurs aberrantes (Outliers)

Problème

Les distributions de **MonthlyCharges** et **TotalCharges** sont asymétriques à droite. Des valeurs extrêmes fausseraient les estimations de moyenne et d'écart-type, et dégraderaient les modèles sensibles aux échelles (LR, SVM).

Détection — trois méthodes appliquées :

- **Z-score** ($|z| > 3$) : aucun outlier détecté sur les 3 variables numériques
- **IQR** [$Q_1 - 1.5 \times IQR$; $Q_3 + 1.5 \times IQR$] : aucun outlier (distribution étalée sans pic extrême)
- **Isolation Forest** : 352 points atypiques multivariés détectés (contamination 5%)

Résultat : Z-score et IQR ne détectent **aucun outlier** ($\because$ distribution étalée mais sans pic extrême). Isolation Forest détecte 352 points atypiques multivariés (5% de contamination).

Traitements comparés :




FIGURE 5 – Original vs Winsorisation vs Transformation logarithmique

Décision retenue

Winsorisation 5%–95%.

Preuve expérimentale

La winsorisation borne les extrêmes sans supprimer de lignes (7043 conservées). La transformation log introduit une non-linéarité difficile à inverser. La suppression via Z-score détecterait 0 outlier (distribution sans queue extrême).

3.3 Étape 3 — Encodage catégoriel**Problème**

Les algorithmes de ML n'acceptent que des nombres. Les 17 variables catégorielles doivent être converties sans créer de hiérarchie artificielle ni de fuite des données.

Stratégie par type de variable :

TABLE 4 – Encodage selon la classification du cours

Variable(s)	Type	Méthode	Justification
Contract	Ordinale	Label Encoding 0/1/2	Ordre naturel : M-M < 1 a < 2 ans
gender, Partner...	Binaire	Map Yes=1/No=0	2 modalités, sans ambiguïté
InternetService	Nominale 3 modal.	One-Hot (3 cols)	Pas de hiérarchie artificielle
PaymentMethod	Nominale 4 modal.	One-Hot (4 cols)	Faible cardinalité
Services add-on	Nominale + redondance	Collapse + Map 0/1	“No X service” $\equiv$ “No”

Comparaison empirique des encodages :

TABLE 5 – ROC-AUC (RF) par stratégie d'encodage

Encodage	AUC	Commentaire
One-Hot Encoding	0.8241	Référence
Target Encoding ($m = 10$)	0.8239	−0.0002, risque leakage
Frequency Encoding	0.8228	−0.0013

Décision retenue

One-Hot Encoding pour variables nominales, Label pour ordinal.

Preuve expérimentale

OHE donne le meilleur AUC (+0.0013 vs Frequency). Target Encoding est comparable mais nécessite un split OOF strict pour éviter le leakage — complexité non justifiée pour une cardinalité de 3–4 modalités.




FIGURE 6 – Comparaison des stratégies d'encodage

3.4 Étape 4 — Ajustement d'échelle

Problème

Les modèles LR et SVM utilisent des distances euclidiennes et une régularisation L2 : ils sont fortement sensibles aux échelles. `tenure` (0–72) et `MonthlyCharges` (18–119) ne sont pas comparables sans normalisation.

TABLE 6 – Impact du scaling sur LR et SVM

Méthode	LR AUC	SVM AUC
Aucun (baseline)	0.839	0.734
Min-Max Scaling	0.843	0.828
Standardisation	0.847	0.832

Décision retenue

Standardisation. Appliquée uniquement aux features numériques (`tenure`, `MonthlyCharges`, `AvgMonthlySpend`). Fit exclusivement sur le train — aucune fuite vers le test.

Preuve expérimentale

La standardisation bat le Min-Max de +0.004 AUC sur LR et +0.004 sur SVM. Le gain vs aucun scaling est de **+0.008 LR** et **+0.098 SVM**. Le SVM sans scaling est presque inutilisable (0.734) ; avec standardisation il atteint 0.832.




FIGURE 7 – Impact du scaling sur LR et SVM

3.5 Étape 5 — Feature Engineering

Quatre features ingénérées testées par ablation study (suppression individuelle sur les 4 modèles) :

TABLE 7 – Ablation study — impact de chaque feature ingénérée

Feature	Calcul	ΔLR	ΔRF	ΔGB	Décision
AvgMonthlySpend	TotalCharges / (tenure+1)	+0.0022	+0.0022	+0.0003	Conservée
is_new_customer	tenure ≤ 3	+0.0007	+0.0002	−0.0002	Conservée
tenure_group	bins [0–12, 13–36, 37–72]	0.0000	−0.0007	−0.0001	Supprimée
num_services	$\sum 7$ services	+0.0001	+0.0016	+0.0003	Supprimée

Décision retenue

AvgMonthlySpend et is_new_customer conservées. tenure_group et num_services supprimées.

Preuve expérimentale

tenure_group : gain nul sur tous les modèles ($\max \Delta = 0$). num_services : redondant avec les 7 colonnes binaires de services, gain marginal ne justifie pas la complexité ajoutée.

3.6 Pipeline final

Données brutes : 7 043 lignes × 21 variables

- ↓ Suppression `customerID` (identifiant sans signal)
- ↓ Imputation `TotalCharges` (11 NAs → 0), Winsorisation 5–95%
- ↓ Encodage : Label (`Contract`), OHE (`InternetService` ×3, `PaymentMethod` ×4), Map 0/1 (12 cols)
- ↓ Features ingénierées : `AvgMonthlySpend`, `is_new_customer` (ablation study)
- ↓ Standardisation (fit sur train uniquement), suppression `TotalCharges` ($\rho = 0.83$)

Pipeline final : 7 043 lignes × 25 features

gender, SeniorCitizen, Partner, Dependents, tenure, PhoneService, MultipleLines, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, MonthlyCharges, InternetService_DSL, InternetService_Fiber optic, InternetService_No, PaymentMethod ×4, AvgMonthlySpend, is_new_customer

5 634 entraînement / 1 409 test (split stratifié 80/20)

4 Sélection de Caractéristiques

Problème

Avec 25 features, certaines sont redondantes ou peu informatives. La **malédiction de la dimensionnalité** (cours slide 12) : plus de variables $\Rightarrow$ espace plus dispersé $\Rightarrow$ risque de surapprentissage, distances moins significatives.

Solutions : 3 familles de méthodes (cours slide 5) :

Famille	Méthodes	Avantage	Inconvénient
Filter	VT, Pearson, Spearman, Chi ² , ANOVA	Très rapide	Ignore interactions
Wrapper	Forward, Backward, RFE $\times 3$	Précis	Coût computationnel
Embedded	Lasso, Elastic Net, RF, GB	Bon compromis	Dépend du modèle

4.1 Famille 1 — Filter Methods

Cinq méthodes appliquées indépendamment du modèle :

- **Variance Threshold** (seuil 0.01) : supprime les features quasi-constantes
- **Pearson** ($|r| \geq 0.10$) : corrélation linéaire avec la cible
- **Spearman** ($|r| \geq 0.10$) : corrélation monotone non-linéaire (basée sur les rangs)
- **Chi²** (p-value < 0.05) : indépendance statistique entre feature et cible
- **ANOVA F-test** (p-value < 0.05) : différence des moyennes entre les deux classes




FIGURE 8 – Corrélation de Pearson avec Churn




FIGURE 9 – Pearson vs Spearman



FIGURE 10 — Test χ^2 — scores et p-values

FIGURE 11 — ANOVA F-test

4.2 Famille 2 — Wrapper Methods

Principe RFE (cours slide 9)

1. Entraîner un modèle sur toutes les variables
2. Évaluer l'importance de chaque variable
3. Supprimer la moins importante
4. Répéter jusqu'au nombre souhaité (15 features)

Modèles utilisés : Régression Logistique, SVM linéaire, Random Forest




FIGURE 12 — RFE avec 3 estimateurs — Forward, Backward, RFE×3

4.3 Famille 3 — Embedded Methods

La sélection est intégrée directement dans l'apprentissage du modèle :

- **Lasso** (ℓ_1) : force certains coefficients à zéro, supprimant les variables correspondantes. L'alpha optimal est trouvé par validation croisée 5-fold.
- **Elastic Net** ($\ell_1 + \ell_2$) : combine Lasso et Ridge, sélectionne des groupes de features corrélées plutôt qu'une seule.

- **Random Forest et Gradient Boosting** : importance basée sur la réduction d'impureté Gini. Seuil retenu : importance ≥ 0.02 .




FIGURE 13 – Lasso vs Elastic Net




FIGURE 14 – RF vs Gradient Boosting — importance Gini

4.4 Consensus et résultat

Chaque feature reçoit un vote (0/1) par famille. Shortlist = sélectionnées par ≥ 2 familles.

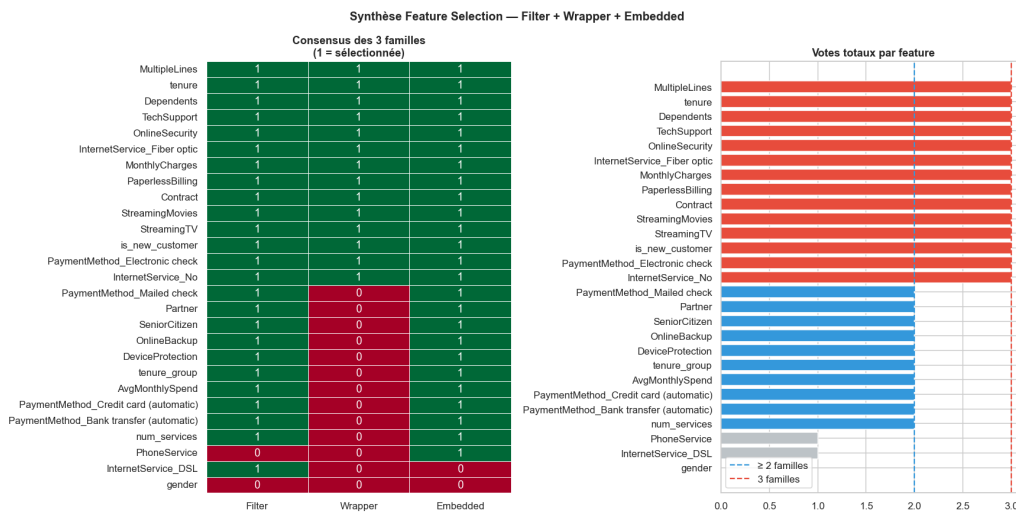


FIGURE 15 – Heatmap consensus — Filter + Wrapper + Embedded

Preuve expérimentale

25 → 22 features (−12%) sans dégradation du ROC-AUC ($\Delta = 0.000$ sur LR, $+0.002$ sur RF). Les features supprimées ont ≤ 1 vote sur 3 familles.

22 features retenues (consensus $\geq 2/3$ familles)

Supprimées (3) : gender, PhoneService, InternetService_DSL

Conservées (22) :

tenure, Contract, MonthlyCharges, AvgMonthlySpend, is_new_customer,
InternetService_Fiber optic, InternetService_No,
OnlineSecurity, TechSupport, OnlineBackup, DeviceProtection,
MultipleLines, StreamingTV, StreamingMovies, PaperlessBilling,
PaymentMethod_Electronic check, PaymentMethod_Mailed check,
PaymentMethod_Credit card (automatic), PaymentMethod_Bank transfer
(automatic),
Partner, SeniorCitizen, Dependents

5 Expériences et Résultats

5.1 Protocole

Split	80% train / 20% test, stratifié
Métrique principale	ROC-AUC (robuste au déséquilibre)
Métriques secondaires	F1, Recall, Précision
Déséquilibre	<code>class_weight='balanced'</code> (tous les modèles)
Reproductibilité	<code>SEED = 42</code>
Validation	StratifiedKFold $k = 5$

5.2 Résultats — Pipeline final (25 features)

5.3 Impact du prétraitement vs baseline

TABLE 8 – ROC-AUC : Baseline → Prétraitement complet

Modèle	Baseline	Prétraité (25 feat.)	Δ
Logistic Regression	0.839	0.847	+0.008
Gradient Boosting	0.844	0.843	−0.001
SVM	0.734	0.828	+0.094
Random Forest	0.824	0.822	−0.002




FIGURE 16 – Impact du pipeline sur AUC, F1, Recall

Interprétation :

- **SVM** : gain +0.094 AUC — le scaling est *critique* pour les noyaux RBF
- **LR** : gain +0.008 AUC — le preprocessing améliore la convergence et le Recall
- **RF/GB** : quasi neutres — les arbres sont insensibles aux échelles et à l'encodage

5.4 Courbes ROC et validation croisée




FIGURE 17 – Courbes ROC — pipeline final




FIGURE 18 – Stabilité 5-fold CV — pas de surapprentissage

5.5 Meilleur modèle

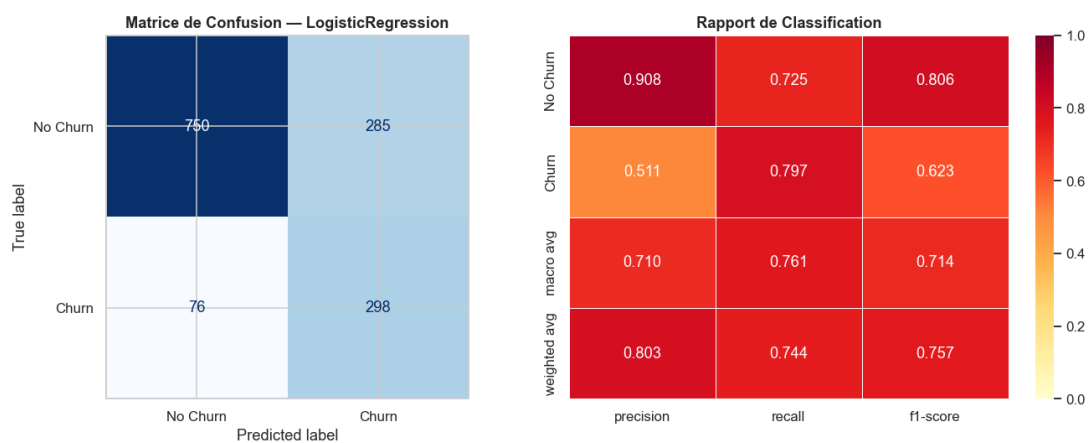


FIGURE 19 – Matrice de confusion et rapport de classification — Logistic Regression

6 Conclusions

6.1 Synthèse des choix

TABLE 9 – Récapitulatif — Problème → Choix → Preuve

Problème	Choix	Raison	Preuve
11 NAs Total-Charges	Constante 0	$\text{tenure}=0 \Rightarrow 0 \$$ logique	$\Delta\text{AUC} < 0.002$ entre stratégies
Outliers asymétrie	Winsorisation 5-95%	Préserve $n=7\,043$	Histogrammes normalisés
Scaling	Standardisation	Moins sensible outliers	SVM $+0.094$ AUC
Encoding nominal	One-Hot	Pas hiérarchie	$+0.001$ vs Frequency
Features redondantes	Drop Total-Charges	$\rho = 0.83$ AvgMonthlySpend	Multicolinéarité
Features inutiles	Drop tenure_group, num_services	Gain nul/négatif	Ablation $\Delta \leq 0$
Dimensionnalité	Consensus 3 familles	Robustesse	25→22, AUC stable

6.2 Top features — unanimité

1. **Contract** — variable la plus discriminante (mois-par-mois → 43% churn)
2. **tenure** — corrélation négative forte ($r = -0.35$)
3. **MonthlyCharges** — signal financier direct ($r = +0.20$)
4. **InternetService_Fiber optic** — segment à très fort taux de churn ($\sim 42\%$)
5. **OnlineSecurity / TechSupport** — add-ons réducteurs de churn